

2ESPB - GS2026 – DynProg

Relatório Técnico

1. Contextualização e Justificativa

Grupo: Davi Correa Paião (RM: 560438), Marcos Vinicius Gonçalves Santos (RM: 560062), Matheus Ricardo Parreira da Silva (RM: 560099).

Cenários Escolhidos:

- **Cenário A (Seca no MATOPIBA):** Essencial devido às severas perdas de safra na região. Utilizamos dados sintéticos que mimetizam anomalias de NDVI (MODIS), criando grandes clusters de alto risco logístico e necessidade de alocação de insumos.
- **Cenário B (Inundações no Sul):** Simula a malha de 478 municípios afetados no RS em 2024. A topologia impõe células bloqueadas (custo = -1) representando pontes caídas e acesso fluvial exclusivo, testando a robustez dos algoritmos de desvio de rotas.

2. Formulação Matemática

O problema exige a minimização do custo logístico simultaneamente à maximização da cobertura de áreas de alto risco. Modelamos isso através do custo efetivo ponderado: $W[i][j] = c[i][j] \times (1 - r[i][j])$. A recorrência da Programação Dinâmica assume subestrutura ótima, garantindo que o subcaminho de (0,0) até (i,j) contido no caminho ótimo total também é ótimo.

A recorrência é definida por:

$$dp[i][j] = W[i][j] + \min(dp[i-1][j], dp[i][j-1])$$

Condições e Casos Base:


- Bloqueio: Se $c[i][j] = -1$, então $W[i][j] = \infty$
- Origem: $dp[0][0] = W[0][0]$.
- Bordas (Direção única): $dp[i][0] = dp[i-1][0] + W[i][0]$ e $dp[0][j] = dp[0][j-1] + W[0][j]$.
- O destino final é dado pela menor célula na fronteira: $\min_{\{j\}} dp[N-1][j], \min_{\{i\}} dp[i][M-1]$.

3. Análise de Complexidade Teórica

- **Força Bruta:** Tempo $O(2^{N+M})$ pois em cada célula existem no máximo 2 decisões (direita, baixo). O espaço é $O(N+M)$ relativo à profundidade da pilha de recursão.
- **Programação Dinâmica (Bottom-up):** Tempo $O(N \times M)$ iterando por todas as células da matriz. Espaço $O(N \times M)$ para armazenar a tabela dp. Totalmente escalável para grades 100×100 .
- **Monte Carlo:** Tempo $O(K \times N \times M)$, pois executa o algoritmo DP K vezes. Sendo $K = 10.000$, exige otimização do laço interno. O espaço extra é $O(K)$ para gravar os custos ótimos.

4. Resultados e Interpretações Visuais

Figura 1: Gráfico de Dispersão Custo Ótimo x Tempo Computacional (Trade-off)




Eixo X representa o tempo de execução em milissegundos; Eixo Y representa o custo ótimo calculado pela função objetivo.

A análise revela a superioridade absoluta da Programação Dinâmica sobre a Força Bruta. Ambas encontram o mesmo custo ótimo (garantia de corretude), porém a DP resolve instâncias dez vezes maiores em uma fração de milissegundos. O algoritmo de Monte Carlo, embora exija o maior tempo computacional, justifica seu uso ao entregar a média do custo ótimo sob incerteza estocástica, posicionando-se como uma ferramenta de planejamento de médio prazo, enquanto a DP pura atende resgates emergenciais.

Fonte: Dados sintéticos gerados via módulo `performance_monitor.py` (simulando instâncias $N=M=5$ e $N=M=50$).

Figura 2: Histograma e Boxplot da Distribuição de Custos (Monte Carlo)




Distribuição de 10.000 cenários simulados, com a curva de densidade (KDE) sobreposta ao histograma e boxplot superior evidenciando quartis e *outliers*.

A simulação demonstra que, sob incerteza climática e logística, o custo de atendimento tende a se concentrar em torno de uma média de 150 unidades normalizadas. A simetria da curva e a dispersão contida no boxplot permitem calcular um Intervalo de Confiança de 95% altamente confiável. Isso garante aos órgãos de defesa civil uma margem de segurança financeira realista para acionamento de frotas e suprimentos em cenários como secas severas ou enchentes.

Fonte: Simulação estocástica (monte_carlo.py) com probabilidades amostradas via distribuição Beta.

Figura 3: Mapa de Calor (Heatmap) da Tabela DP e Caminho Ótimo




Grade geoespacial 5x5. Cores mais quentes (vermelho escuro) indicam alto custo logístico acumulado. A linha azul traceja o caminho ótimo da origem (0,0) até o destino.

O algoritmo demonstra com sucesso a capacidade de desviar de zonas de "penalidade" logística (células vermelhas). Observa-se que o caminho azul busca ativamente transitar por células de tonalidade mais clara (menor custo efetivo ponderado pelo risco). Esta validação visual comprova que a subestrutura ótima da equação de Bellman foi implementada corretamente, garantindo que as equipes de campo não fiquem presas em gargalos geográficos intransponíveis.

Fonte: Matriz de custo efetivo calculada via `dynamic_programming.py`

Figura 4: Curva de Escalabilidade Empírica (Tempo x N)




Eixo Y em escala logarítmica (base 10) representando tempo em milissegundos. Eixo X reflete o crescimento da grade quadrada ($N=M$).

O gráfico escancara a inviabilidade prática da Força Bruta (linha azul tracejada), cujo tempo explode exponencialmente logo nos primeiros incrementos ($N=5$). Em forte contraste, a Programação Dinâmica (linha laranja) mantém um crescimento suave e previsível, alinhado à sua complexidade teórica polinomial. O Monte Carlo (linha verde) comporta-se como um multiplicador linear constante sobre a curva da DP, provando ser perfeitamente escalável para grades maiores caso haja disponibilidade de processamento em nuvem.

Fonte: Testes de carga do módulo `performance_monitor.py` limitados a $N=50$.

Figura 5: Análise de Sensibilidade da Incerteza Agroclimática



Comparativo de densidade de custo entre o cenário base (azul), um cenário com 20% de redução no risco (laranja) e outro com 20% de elevação (verde).

O deslocamento das curvas ilustra claramente a sensibilidade da malha logística às anomalias climáticas. Um agravamento de 20% no risco (curva verde) não apenas aumenta a média do custo financeiro de resposta, como achata a curva, indicando maior variância e imprevisibilidade. Isso reforça a necessidade tecnológica de integrar os dados satelitais em tempo real: o atraso na atualização do índice de risco pode subestimar drasticamente o custo real de uma operação de resgate ou fornecimento de insumos.

Fonte: Variações do parâmetro $p[i][j]$ inseridas no modelo Monte Carlo.

5. Escala de Decisão

Com base na análise de restrição (Trade-off de tempo vs custo), a escala de decisão para acionamento na plataforma é:

1. **Nível 1 (Crise Imediata - Inundação Sul):** Exige cálculo de rota em <10ms. Usamos puramente o algoritmo de DP 2D sem simulação Monte Carlo. Risco logístico é isolado e contornado.
2. **Nível 2 (Planejamento Tático - Seca MATOPIBA):** Necessita de avaliação de risco. Acionamento de Monte Carlo com K=10.000. Leva alguns segundos, mas entrega o IC 95% para embasar o orçamento logístico.
3. **Nível 3 (Análise Sensível):** Execução do MC com variação de $p[i][j]$ +- 20% para mapear cenários de degradação climática severa (El Niño).

6. Conclusão e Conexão ODS

A solução via Programação Dinâmica provou-se altamente eficiente na otimização de resposta rápida. Conectamos diretamente aos **ODS 9 e 13** ao utilizar infraestrutura de dados orbitais resilientes (NASA/ESA) para ação climática direta. Ao agilizar o resgate em inundações e focar nas secas, ataca-se o **ODS 2** (proteção à agricultura contra eventos extremos). Recomenda-se a implementação em nuvem pública (AWS/GCP) da Defesa Civil Nacional.

7. Referências

- NASA Earthdata (MODIS NDVI, SRTM): earthdata.nasa.gov
- ESA Copernicus Open Access Hub (Sentinel-1/2): scihub.copernicus.eu
- INPE PRODES/DETER (desmatamento Amazônia): terrabrasilis.dpi.inpe.br
- ANA — Agência Nacional de Águas (pluviometria): hidroweb.ana.gov.br
- INMET (dados climáticos): bdmep.inmet.gov.br
- ANATEL (conectividade): mapa.anatel.gov.br
- Bellman, R. (1957). Dynamic Programming. Princeton University Press.
- Cormen, T. et al. (2022). Introduction to Algorithms, 4th Ed. MIT Press.
- Kroese, D. P. et al. (2011). Handbook of Monte Carlo Methods. Wiley.
- Carta Internacional Space and Major Disasters: disasterscharter.org
- NASA Artemis Program: nasa.gov/artemis
- ESA Earth Observation: esa.int/Applications/Observing_the_Earth/global-solution-2026-dynProg